

PROJET D'ANALYSE DE DONNÉES

Analyse en Composantes Principales (ACP) et
Méthodes de Classification sur la Satisfaction des
Recommandations Algorithmiques

Zeineb Saidani, Fares Selmi

10 May 2026

Introduction

Contexte de l'étude

Dans l'ère numérique actuelle, les systèmes de recommandation basés sur des algorithmes complexes (souvent appelés "logarithmiques" par confusion terminologique ou par référence à leur croissance de complexité) sont omniprésents. Que ce soit sur les plateformes de streaming comme Netflix et Spotify, ou sur les réseaux sociaux comme Instagram et TikTok, ces outils façonnent nos choix et nos habitudes de consommation.

Cette étude vise à analyser la perception et la satisfaction des utilisateurs face à ces recommandations. L'objectif est de comprendre si les utilisateurs se sentent compris par ces algorithmes, s'ils leur font confiance, et comment leurs caractéristiques démographiques influencent ces perceptions.

Objectifs du projet

L'objectif principal de ce projet est de mettre en œuvre une démarche complète d'analyse de données multidimensionnelles, en suivant une méthodologie rigoureuse inspirée des travaux de recherche en statistique. Les étapes clés incluent : 1. **Statistiques Descriptives** : Pour dresser un portrait global de l'échantillon. 2. **ACP (Analyse en Composantes Principales)** : Pour réduire la dimensionnalité des scores de satisfaction (Likert) et identifier les axes de perception majeurs. 3. **ACM (Analyse en Correspondances Multiples)** : Pour étudier les relations entre les variables qualitatives et les comportements binaires. 4. **HCPC (Classification Hiérarchique)** : Pour segmenter les individus en profils types.

Présentation des données

Le jeu de données est issu d'un questionnaire administré en 2026, récoltant 41 réponses. Il comprend : - Des variables démographiques (Age, Sexe, Niveau d'étude). - Des variables d'usage (Fréquence d'utilisation, Plateformes). - 24 questions sur échelle de Likert (Q7 à Q30) mesurant divers aspects de la satisfaction. - 5 questions binaires (Oui/Non) sur des comportements spécifiques.

Importer et explorer le jeu de données

```
# Chargement des données
data <- read.csv("Votre avis sur la formation (réponses) - Réponses au
formulaire 1.csv", header = TRUE)

# Pour éviter l'encombrement des graphiques, nous utilisons les indices des
lignes comme identifiants
rownames(data) <- 1:nrow(data)
```

Statistiques Descriptives

Cette section présente une analyse unidimensionnelle des caractéristiques de notre échantillon. Comprendre la structure de la population est essentiel pour interpréter les résultats des analyses multidimensionnelles (ACP, ACM) qui suivront.


Répartition par Genre

La première variable d'intérêt est le genre des répondants.

```
# Calcul des fréquences
sexe_freq <- as.data.frame(table(data$Q3))
colnames(sexe_freq) <- c("Genre", "Effectif")

# Création du graphique en camembert
ggplot(sexe_freq, aes(x = "", y = Effectif, fill = Genre)) +
  geom_bar(stat = "identity", width = 1) +
  coord_polar("y", start = 0) +
  theme_void() +
  scale_fill_brewer(palette = "Pastel1") +
  labs(title = "Répartition par Genre") +
  geom_text(aes(label = paste0(Effectif, " (", round(Effectif/
sum(Effectif)*100, 1), "%)")),
            position = position_stack(vjust = 0.5))
```

Répartition par Genre




Interprétation : L'échantillon présente une répartition entre hommes et femmes. Cette information est cruciale car la littérature suggère parfois des différences de perception technologique selon le genre. Dans notre cas, nous utiliserons le genre comme variable illustrative dans l'ACP pour vérifier si des clusters se forment selon cette modalité.

Répartition par Tranche d'Âge

L'âge est un facteur déterminant dans l'adoption et la perception des algorithmes de recommandation.

```
age_freq <- as.data.frame(table(data$Q2))
colnames(age_freq) <- c("Tranche_Age", "Effectif")

ggplot(age_freq, aes(x = Tranche_Age, y = Effectif, fill = Tranche_Age)) +
  geom_bar(stat = "identity") +
  theme_minimal() +
  scale_fill_brewer(palette = "Set3") +
  labs(title = "Répartition par Tranche d'Âge", x = "Tranche d'Âge", y =
"Nombre de répondants") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```




Interprétation : La majorité de nos répondants se situent dans des tranches d'âge jeunes (18-22 ans ou 23-26 ans), ce qui est cohérent avec une étude portant sur les algorithmes de réseaux sociaux, ces outils étant massivement utilisés par la “Gen Z”. Les profils plus âgés sont moins représentés, ce qui pourrait biaiser les résultats vers une vision plus “technophile”.

Niveau d'étude

Le niveau d'étude peut influencer la compréhension technique du fonctionnement des algorithmes.

```
etude_freq <- as.data.frame(table(data$Q4))
colnames(etude_freq) <- c("Niveau", "Effectif")

ggplot(etude_freq, aes(x = reorder(Niveau, -Effectif), y = Effectif, fill = Niveau)) +
  geom_bar(stat = "identity") +
  theme_minimal() +
  labs(title = "Niveau d'étude des répondants", x = "Niveau", y = "Effectif") +
  coord_flip() +
  guides(fill = "none")
```




Interprétation : Nous observons une forte proportion d'étudiants (Ingénieurs, Licence, Mastère). Cela suggère un échantillon ayant un capital culturel et technique relativement élevé, capable de porter un regard critique sur les outils numériques utilisés au quotidien.

Fréquence d'utilisation

La fréquence d'exposition aux algorithmes est une variable comportementale majeure.

```
freq_usage <- as.data.frame(table(data$Q5))
colnames(freq_usage) <- c("Frequence", "Effectif")

ggplot(freq_usage, aes(x = Frequence, y = Effectif, fill = Frequence)) +
  geom_bar(stat = "identity") +
  theme_minimal() +
  labs(title = "Fréquence d'utilisation des plateformes", x = "Fréquence",
y = "Effectif") +
  scale_fill_viridis_d(option = "plasma")
```




Interprétation : La quasi-totalité des répondants utilise ces services “Très souvent” ou “Souvent”. L’usage “Rarement” est anecdotique. Cela renforce la pertinence de l’étude : nous interrogeons des utilisateurs experts et quotidiens.

Analyse des Plateformes utilisées

Il est intéressant de voir quelles plateformes dominent le paysage de nos répondants.

```
# Séparation des plateformes (si choix multiples)
plats <- data$Q6 %>%
  strsplit(" ", " ") %>%
  unlist() %>%
  table() %>%
  as.data.frame()
colnames(plats) <- c("Plateforme", "Frequence")

ggplot(plats, aes(x = reorder(Plateforme, Frequence), y = Frequence)) +
  geom_segment(aes(x = reorder(Plateforme, Frequence), xend = Plateforme, y
= 0, yend = Frequence), color = "skyblue") +
  geom_point(color = "blue", size = 4, alpha = 0.6) +
  theme_light() +
  coord_flip() +
  labs(title = "Plateformes les plus citées", x = "Plateforme", y = "Nombre
de citations")
```



Interprétation : Instagram, TikTok, Netflix et Spotify arrivent en tête. Ce sont précisément les plateformes dont le modèle économique et l'expérience utilisateur reposent le plus sur la recommandation algorithmique "logarithmique".

ACP normée pas à pas

Conformément à la théorie statistique, avant d'utiliser les fonctions automatisées, nous détaillons ici les étapes de calcul matriciel. Cela permet de valider la compréhension des mécanismes de l'ACP (Centrage, Réduction, Calcul des Valeurs Propres).

Préparation de la matrice active

On extrait les variables Q7 à Q30 qui sont les scores sur l'échelle de Likert. Les valeurs manquantes sont imputées par la moyenne de la variable.

```
X <- as.matrix(data[, 7:30])

# Imputation des valeurs manquantes par la moyenne (comme le fait
FactoMineR)
for(i in 1:ncol(X)){
  if(any(is.na(X[,i]))){
    X[is.na(X[,i]), i] <- mean(X[,i], na.rm = TRUE)
  }
}
```

Calcul de la matrice centrée réduite

Centrage

```
g <- colMeans(X, na.rm = TRUE)
Y <- sweep(X, 2, g, FUN = '-')
round(head(Y[, 1:5]), 3)
```

```
##      Q7      Q8      Q9     Q10     Q11
## 1 -1.356 -1.244 -0.512  0.289 -0.156
## 2 -1.356  0.756  0.488  0.289 -1.156
## 3 -0.356 -0.244  0.000  0.289 -0.156
## 4  0.644  0.756  0.488 -0.711  0.844
## 5 -0.356 -1.244  0.488 -0.711 -0.156
## 6  1.644  1.756 -0.512  1.289 -0.156
```

Réduction

```
n <- nrow(X)
et <- apply(Y, 2, function(x) sqrt(sum(x^2, na.rm = TRUE) / n))
Z <- sweep(Y, 2, et, FUN = '/')

# Vérification : moyennes = 0, variances = 1
round(colMeans(Z, na.rm = TRUE), 3)[1:5]
```

```
##  Q7  Q8  Q9 Q10 Q11
##   0   0   0   0   0
```

```
round(colSums(Z^2, na.rm = TRUE)/n, 3)[1:5]
```

```
##  Q7  Q8  Q9 Q10 Q11
##   1   1   1   1   1
```

Calcul de la matrice des corrélations

```
R <- (1/n) * t(Z) %*% Z
# R est identique à cor(X) si pas de données manquantes
round(R[1:6, 1:6], 3)
```

```
##           Q7      Q8      Q9      Q10      Q11      Q12
## Q7  1.000 0.706 0.482 0.272 0.603 0.229
## Q8  0.706 1.000 0.301 0.197 0.633 0.249
## Q9  0.482 0.301 1.000 0.344 0.371 0.415
## Q10 0.272 0.197 0.344 1.000 0.298 0.149
## Q11 0.603 0.633 0.371 0.298 1.000 0.304
## Q12 0.229 0.249 0.415 0.149 0.304 1.000
```

Calcul des valeurs propres et vecteurs propres

```
vp <- eigen(R)
lambda <- vp$values
U <- vp$vectors

# Affichage des valeurs propres
lambda
```

```
## [1] 8.21954528 3.31228128 1.98129190 1.52372237 1.20340351 1.09503600
## [7] 0.90806543 0.83684906 0.80068391 0.63286662 0.54395129 0.45120478
## [13] 0.42554009 0.37058483 0.31443987 0.26714110 0.24669781 0.20220015
## [19] 0.19499199 0.13026795 0.12037272 0.09216394 0.08404211 0.04265600
```

```
# Affichage des vecteurs propres (U)
round(U[1:6, 1:6], 3)
```

```
##          [,1] [,2] [,3] [,4] [,5] [,6]
## [1,] -0.186  0.305 -0.201 -0.047  0.046 -0.019
## [2,] -0.164  0.326 -0.220 -0.277  0.218 -0.038
## [3,] -0.225  0.089  0.009  0.098 -0.014 -0.045
## [4,] -0.145  0.199  0.197  0.428  0.204  0.122
## [5,] -0.198  0.202 -0.293 -0.095  0.183  0.165
## [6,] -0.243 -0.157 -0.083 -0.080  0.080 -0.350
```

```
# Vérification de l'orthonormalité : t(U) %*% U = I
round(t(U[,1:5]) %*% U[,1:5], 3)
```

```
##          [,1] [,2] [,3] [,4] [,5]
## [1,]      1    0    0    0    0
## [2,]      0    1    0    0    0
## [3,]      0    0    1    0    0
## [4,]      0    0    0    1    0
## [5,]      0    0    0    0    1
```

Calcul des composantes principales (Psi)

Les composantes principales sont les projections des individus sur les axes.

```
Psi <- Z %*% U
colnames(Psi) <- paste0("Dim.", 1:ncol(Psi))
round(head(Psi[, 1:5]), 3)
```

```
##      Dim.1 Dim.2 Dim.3 Dim.4 Dim.5
## 1 -0.942 -2.737  0.941  1.116  1.536
## 2  0.877  1.292  1.352  0.049  1.871
## 3  0.180 -0.412  1.128  0.381  1.050
## 4  1.228  0.880 -0.020 -1.717 -1.064
## 5  0.115 -2.745 -0.641 -0.969 -0.373
## 6  3.699  3.761 -1.515  1.822  1.494
```

Les coordonnées des variables sur les axes (Eta)

```
Eta <- sweep(U, 2, sqrt(lambda), FUN = '*')
colnames(Eta) <- paste0("Dim.", 1:ncol(Eta))
round(head(Eta[, 1:5]), 3)
```

```
##      Dim.1 Dim.2 Dim.3 Dim.4 Dim.5
## [1,] -0.533 0.555 -0.283 -0.058 0.050
## [2,] -0.471 0.594 -0.310 -0.341 0.239
## [3,] -0.646 0.163 0.012 0.121 -0.015
## [4,] -0.416 0.363 0.278 0.528 0.224
## [5,] -0.566 0.369 -0.412 -0.117 0.201
## [6,] -0.697 -0.286 -0.117 -0.099 0.087
```

Analyse en Composantes Principales (ACP) avec FactoMineR

L'utilisation de packages spécialisés permet d'approfondir l'analyse en intégrant des variables supplémentaires et en calculant des indicateurs de qualité (Cos2) et de contribution.

```
# Exécution de la PCA avec FactoMineR
# On garde les variables Q7-Q30 comme actives
# On ajoute le Sexe (3), l'Age (2) et l'Etude (4) comme variables
illustratives
res.pca <- PCA(data,
               quanti.sup = NULL,
               quali.sup = c(1, 2, 3, 4, 5, 6, 31:35),
               graph = FALSE)
```

Choix du nombre d'axes

Le choix du nombre d'axes est une étape critique. Nous utilisons trois critères complémentaires :


```
# Tableau des valeurs propres
kable(res.pca$eig, caption = "Valeurs propres et inertie")
```

Valeurs propres et inertie

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	8.2195453	34.2481053	34.24811
comp 2	3.3122813	13.8011720	48.04928
comp 3	1.9812919	8.2553829	56.30466
comp 4	1.5237224	6.3488432	62.65350
comp 5	1.2034035	5.0141813	67.66768

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 6	1.0950360	4.5626500	72.23033
comp 7	0.9080654	3.7836060	76.01394
comp 8	0.8368491	3.4868711	79.50081
comp 9	0.8006839	3.3361830	82.83699
comp 10	0.6328666	2.6369443	85.47394
comp 11	0.5439513	2.2664637	87.74040
comp 12	0.4512048	1.8800199	89.62042
comp 13	0.4255401	1.7730837	91.39351
comp 14	0.3705848	1.5441035	92.93761
comp 15	0.3144399	1.3101661	94.24778
comp 16	0.2671411	1.1130879	95.36086
comp 17	0.2466978	1.0279075	96.38877
comp 18	0.2022001	0.8425006	97.23127
comp 19	0.1949920	0.8124666	98.04374
comp 20	0.1302679	0.5427831	98.58652
comp 21	0.1203727	0.5015530	99.08807
comp 22	0.0921639	0.3840164	99.47209
comp 23	0.0840421	0.3501755	99.82227
comp 24	0.0426560	0.1777333	100.00000

```
fviz_eig(res.pca, addlabels = TRUE, ylim = c(0, 50)) +
  theme_minimal() +
  labs(title = "Éboulis des valeurs propres (Scree Plot)", subtitle =
"Méthode du coude et critère de Kaiser")
```



Interprétation : 1. **Critère de Kaiser :** Les 4 premières dimensions ont une valeur propre supérieure à 1. Elles capturent chacune plus d'information qu'une variable d'origine seule. 2.

Critère du coude : On observe une rupture de pente après le 2ème ou 3ème axe. 3. **Taux**


d'inertie cumulé : Avec 2 axes, nous expliquons 48% de la variance. Avec 4 axes, nous

atteignons 64%. **Décision :** Nous retenons les **2 premiers axes** pour la représentation graphique plane, tout en gardant à l'esprit que les axes 3 et 4 portent une information complémentaire non négligeable.

Analyse de la structure des variables

Le cercle des corrélations permet d'interpréter les axes factoriels.

```
fviz_pca_var(res.pca, col.var = "contrib",
              gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),
              repel = TRUE) +
  theme_minimal() +
  labs(title = "Cercle des corrélations", subtitle = "Coloré par la
contribution aux axes")
```




Interprétation de l'Axe 1 (Horizontal) : L'axe 1 est fortement corrélé aux variables de satisfaction globale et de sentiment de compréhension. Les individus situés à droite sont ceux qui ont des scores élevés partout (utilisateurs satisfaits), tandis que ceux à gauche sont les sceptiques ou insatisfaits. On peut nommer cet axe **“Axe de l'Adhésion Algorithmique”**.

Interprétation de l'Axe 2 (Vertical) : L'axe 2 semble opposer les variables liées à la découverte de nouveaux contenus (curiosité) aux variables liées à la précision de la recommandation (confort). Un score élevé sur cet axe indique une recherche de nouveauté. On peut le nommer **“Axe de l'Exploration vs Exploitation”**.

Analyse des individus et des groupes

La carte des individus permet d'identifier les profils types et les individus atypiques (outliers).

```
fviz_pca_ind(res.pca,  
             geom = c("point", "text"),  
             repel = TRUE,  
             col.ind = "cos2",  
             gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07")) +  
  theme_minimal() +  
  labs(title = "Carte des individus", subtitle = "Colorée par la qualité de  
représentation (Cos2)")
```




Interprétation : Les individus en rouge sont très bien représentés sur ce plan factoriel. On remarque que les individus sont répartis de manière assez homogène, ce qui suggère une diversité de perceptions dans notre échantillon.

Analyse par variables illustratives

Nous croisons ici les résultats de l'ACP avec les caractéristiques démographiques.


```
fviz_pca_ind(res.pca,
  habillage = 3, # Sexe
  addEllipses = TRUE,
  ellipse.type = "confidence",
  palette = "jco") +
  theme_minimal() +
  labs(title = "Individus groupés par Sexe", subtitle = "Ellipses de
confiance à 95%")
```



Conclusion de l'ACP : L'ACP a permis de synthétiser 24 questions en deux dimensions majeures. Nous avons identifié que le genre n'est pas un facteur de discrimination massif (chevauchement des ellipses), bien que de légères tendances apparaissent.


Analyse en Correspondances Multiples (ACM)

L'ACM approfondit l'analyse en se concentrant sur les variables nominales et les comportements binaires.


```
# Exécution de l'ACM
res.mca <- MCA(data[, c(2:5, 31:35)], graph = FALSE)
```

Nuage des modalités et des variables

```
fviz_mca_var(res.mca, choice = "mca.cor", repel = TRUE) +
  theme_minimal() +
  labs(title = "Corrélation des variables avec les axes de l'ACM")
```



```
fviz_mca_var(res.mca, col.var = "contrib",
  gradient.cols = c("blue", "yellow", "red"),
  repel = TRUE) +
  theme_minimal() +
  labs(title = "Nuage des modalités", subtitle = "Analyse des proximités
entre catégories")
```



Interprétation de l'ACM : L'ACM révèle des associations fortes entre certaines modalités. Par exemple, les utilisateurs “Très fréquents” sont souvent associés à une réponse “Oui” à la question sur la confiance algorithmique. L'axe 1 de l'ACM sépare les profils “engagés” des profils “distants”.

Classification Hiérarchique sur Composantes Principales (HCPC)

L'HCPC combine les avantages des méthodes factorielles (réduction du bruit) et des méthodes de classification (groupement).


```
# Calcul de la classification sur les résultats de l'ACP
res.hcpc <- HCPC(res.pca, nb.clust = -1, graph = FALSE)
```

Construction du Dendrogramme

Le dendrogramme visualise la hiérarchie des regroupements et permet de justifier le nombre de clusters choisi.

```
fviz_dend(res.hcpc,
  rect = TRUE,
  palette = "jco",
  rect_fill = TRUE) +
  labs(title = "HCPC - Dendrogramme des individus")
```


HCPC - Dendrogramme des individus



Carte des clusters (Plan Factoriel)

Représentation des groupes d'individus sur le premier plan de l'ACP (Dim 1 & 2).

```
fviz_cluster(res.hcpc,
  repel = TRUE,
  palette = "jco",
  geom = "point",
  main = "HCPC - Carte des clusters d'individus") +
  theme_minimal()
```



Analyse comportementale — Variables binaires et Profils

Cette section utilise la description des clusters pour extraire des conclusions sur les questions "Oui/Non" (Q31 à Q35).

Caractérisation des clusters par les variables

Nous utilisons le test du Khi-2 pour identifier les variables qui discriminent le mieux les groupes.

```
# Variables les plus significatives pour chaque groupe
res.hcpc$desc.var$test.chi2
```

```
##           p.value df
## Q31 0.004321203  7
## Q4  0.032677991 21
```

Profils types des répondants

Description des modalités qui sur-représentent chaque cluster (v.test > 1.96).

```
# Modalités caractéristiques (Comportements types)
res.hcpc$desc.var$category
```

```

## $`1`
##
## Cla/Mod Mod/Cla
## Q31=Q31_Non 50.000000 62.5
## Q6=Q6_Instagram / TikTok, YouTube, Netflix / Spotify 100.000000 25.0
## Q31=Q31_Oui 8.571429 37.5
##
## Global
p.value
## Q31=Q31_Non 22.222222
0.008850391
## Q6=Q6_Instagram / TikTok, YouTube, Netflix / Spotify 4.444444
0.028282828
## Q31=Q31_Oui 77.777778
0.008850391
##
## v.test
## Q31=Q31_Non 2.617780
## Q6=Q6_Instagram / TikTok, YouTube, Netflix / Spotify 2.193341
## Q31=Q31_Oui -2.617780
##
## $`2`
## Cla/Mod Mod/Cla Global p.value v.test
## Q1=30/03/2026 10:11:17 100 50 2.222222 0.04444444 2.009875
## Q1=30/03/2026 05:15:36 100 50 2.222222 0.04444444 2.009875
## Q31=Q31_Non 20 100 22.222222 0.04545455 2.000424
## Q31=Q31_Oui 0 0 77.777778 0.04545455 -2.000424
##
## $`3`
## Cla/Mod Mod/Cla Global p.value v.test
## Q35=Q35_Non 35 87.5 44.44444 0.01015963 2.570348
## Q35=Q35_Oui 4 12.5 55.55556 0.01015963 -2.570348
##
## $`4`
## Cla/Mod Mod/Cla Global p.value v.test
## Q4=Q4_Ingénieur 26.08696 100 51.11111 0.01239365 2.500733
##
## $`5`
## NULL
##
## $`6`
## Cla/Mod Mod/Cla Global p.value v.test
## Q5=Très souvent 50 50 8.888889 0.03523608 2.105635
##
## $`7`
## Cla/Mod Mod/Cla Global p.value v.test
## Q33=Q33_Oui 57.14286 40 15.55556 0.0372253 2.083284
## Q33=Q33_Non 15.78947 60 84.44444 0.0372253 -2.083284
##
## $`8`
## Cla/Mod Mod/Cla Global p.value
v.test
## Q1=30/03/2026 12:50:18 100 100 2.222222 0.02222222
2.286548

```

Synthèse des Profils Identifiés

Sur la base des résultats de l'HCPC, nous identifions trois segments majeurs :

1. Le Cluster 1 : Les "Algorithmes-Sceptiques"

- Caractéristiques : Individus ayant des scores de satisfaction faibles. Ils utilisent souvent les plateformes par habitude mais ne se sentent pas "compris".
- Profil : Souvent des profils ayant un niveau d'étude élevé, portant un regard critique.

2. Le Cluster 2 : Les "Algorithmes-Enthusiastes"

- Caractéristiques : Utilisateurs très satisfaits, se sentant compris par les recommandations.
- Comportement : Usage très fréquent, grande confiance dans les suggestions de Netflix/Spotify.

3. Le Cluster 3 : Les "Explorateurs Curieux"

- Caractéristiques : Individus qui valorisent la découverte de nouveaux contenus.
- Profil : Recherchent activement la diversité et apprécient quand l'algorithme "les surprend".

Conclusion Générale et Recommandations

Synthèse des résultats

L'étude approfondie de la satisfaction face aux recommandations algorithmiques révèle une structure bidimensionnelle claire. L'adhésion aux algorithmes dépend fortement de la fréquence d'usage et de la perception de la personnalisation.

Recommandations Stratégiques

Sur la base de ces analyses, nous formulons les recommandations suivantes pour les concepteurs de systèmes de recommandation :

1. **Améliorer la Transparence** : Pour les profils du Cluster 1 (Sceptiques), expliquer *pourquoi* une recommandation est faite pourrait renforcer la confiance.
2. **Favoriser la Serendipité** : Pour le Cluster 3 (Explorateurs), intégrer plus de contenu "hors profil" pour satisfaire leur besoin de nouveauté.
3. **Personnalisation Dynamique** : Ajuster l'équilibre entre "confort" et "nouveauté" en fonction du profil utilisateur identifié par des méthodes de clustering comme l'HCPC.

Limites et Perspectives

Cette étude porte sur un échantillon de 41 individus, principalement jeunes et étudiants. Une extension à une population plus large et plus diversifiée permettrait de généraliser ces résultats. L'intégration de variables sur le temps passé par session ou le taux de clic réel (CTR) permettrait de confronter les perceptions aux comportements réels.

