

PROJET D'ANALYSE DE DONNÉES

Analyse en Composantes Principales (ACP) et
Méthodes de Classification sur la Satisfaction des
Recommandations Algorithmiques

Zeineb Saidani, Fares Selmi

10 May 2026

Introduction

Contexte de l'étude

Dans l'ère numérique actuelle, les systèmes de recommandation basés sur des algorithmes complexes sont omniprésents. Que ce soit sur les plateformes de streaming comme Netflix et Spotify, ou sur les réseaux sociaux comme Instagram et TikTok, ces outils façonnent nos choix et nos habitudes de consommation.

Cette étude vise à analyser la perception et la satisfaction des utilisateurs face à ces recommandations. L'objectif est de comprendre si les utilisateurs se sentent compris par ces algorithmes, s'ils leur font confiance, et comment leurs caractéristiques démographiques influencent ces perceptions.

Objectifs du projet

L'objectif principal est de mettre en œuvre une démarche complète d'analyse de données multidimensionnelles :

1. **Statistiques Descriptives** : Portrait global de l'échantillon.
2. **ACP** : Réduction de dimensionnalité et identification des axes de perception majeurs.
3. **ACM** : Étude des relations entre les variables qualitatives et comportements binaires.
4. **HCPC & K-means** : Segmentation des individus en profils types.

Présentation des données

```
data <- read.csv("Votre avis sur la formation (réponses) - Réponses au  
formulaire 1.csv",  
                header = TRUE)  
rownames(data) <- 1:nrow(data)
```

Le jeu de données est issu d'un questionnaire administré en 2026, récoltant **45 réponses**. Il comprend des variables démographiques (Age, Sexe, Niveau d'étude), des variables d'usage (Fréquence, Plateformes), 24 questions sur échelle de Likert (Q7 à Q30) et 5 questions binaires (Q31-Q35).

Statistiques Descriptives


Répartition sociodémographique

```
# Genre
sexe_freq <- as.data.frame(table(data$Q3))
colnames(sexe_freq) <- c("Genre", "Effectif")
p1 <- ggplot(sexe_freq, aes(x = "", y = Effectif, fill = Genre)) +
  geom_bar(stat = "identity", width = 1) +
  coord_polar("y", start = 0) + theme_void() +
  scale_fill_brewer(palette = "Pastel1") +
  labs(title = "Répartition par Genre") +
  geom_text(aes(label = paste0(round(Effectif/sum(Effectif)*100, 1), "%")),
    position = position_stack(vjust = 0.5), size = 3)


# Âge
age_freq <- as.data.frame(table(data$Q2))
colnames(age_freq) <- c("Tranche_Age", "Effectif")
p2 <- ggplot(age_freq, aes(x = Tranche_Age, y = Effectif, fill =
  Tranche_Age)) +
  geom_bar(stat = "identity") + theme_minimal() +
  scale_fill_brewer(palette = "Set3") +
  labs(title = "Répartition par Âge", x = "", y = "Effectif") +
  theme(axis.text.x = element_text(angle = 40, hjust = 1), legend.position
    = "none")

gridExtra::grid.arrange(p1, p2, ncol = 2)
```

Répartition par Genre



Répartition par Âge




Interprétation : La majorité des répondants sont jeunes (18-26 ans), cohérent avec une étude sur les algorithmes de réseaux sociaux largement utilisés par la Gen Z.

Niveau d'étude et Fréquence d'utilisation

```
# Niveau d'étude
etude_freq <- as.data.frame(table(data$Q4))
colnames(etude_freq) <- c("Niveau", "Effectif")
p3 <- ggplot(etude_freq, aes(x = reorder(Niveau, -Effectif), y = Effectif,
fill = Niveau)) +
  geom_bar(stat = "identity") + theme_minimal() +
  labs(title = "Niveau d'étude", x = "", y = "Effectif") +
  coord_flip() + guides(fill = "none")

# Fréquence
freq_usage <- as.data.frame(table(data$Q5))
colnames(freq_usage) <- c("Frequence", "Effectif")
p4 <- ggplot(freq_usage, aes(x = Frequence, y = Effectif, fill =
Frequence)) +
  geom_bar(stat = "identity") + theme_minimal() +
  labs(title = "Fréquence d'utilisation", x = "", y = "Effectif") +
  scale_fill_viridis_d(option = "plasma") +
  theme(axis.text.x = element_text(angle = 30, hjust = 1), legend.position
= "none")


gridExtra::grid.arrange(p3, p4, ncol = 2)
```



Interprétation : On observe une forte proportion d'étudiants (Ingénieurs, Licence, Mastère) utilisant ces plateformes très souvent. L'échantillon reflète un profil technophile et critique.

Plateformes les plus utilisées

```
plats <- data$Q6 %>% strsplit(", ") %>% unlist() %>% table() %>%  
as.data.frame()  
colnames(plats) <- c("Plateforme", "Frequence")  
  
ggplot(plats, aes(x = reorder(Plateforme, Frequence), y = Frequence)) +  
  geom_segment(aes(xend = Plateforme, y = 0, yend = Frequence), color =  
"steelblue") +  
  geom_point(color = "navy", size = 3) + theme_light() + coord_flip() +  
  labs(title = "Plateformes les plus citées", x = "", y = "Nombre de  
citations")
```



Interprétation : Instagram, TikTok, Netflix et Spotify dominant — des plateformes dont le modèle repose entièrement sur la recommandation algorithmique.

Analyse en Composantes Principales (ACP)


L'ACP est une méthode de réduction de dimensionnalité qui transforme des variables corrélées en composantes principales décorréées. Nous utilisons ici FactoMineR sur les 24 variables de satisfaction (Q7–Q30), avec les variables démographiques en illustratives.

```
res.pca <- PCA(data,
  quanti.sup = NULL,
  quali.sup = c(1, 2, 3, 4, 5, 6, 31:35),
  graph = FALSE)
```

Choix du nombre d'axes

```
p_screes <- fviz_eig(res.pca, addlabels = TRUE, ylim = c(0, 50)) +
  theme_minimal() +
  labs(title = "Éboulis des valeurs propres (Scree Plot)")

print(p_screes)
```



```
kable(round(res.pca$eig[1:6, ], 3), caption = "Valeurs propres et taux  
d'inertie (6 premiers axes)")
```

Valeurs propres et taux d'inertie (6 premiers axes)

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	18.220	34.248	34.248
comp 2	23.312	13.801	48.049
comp 3	31.981	8.255	56.305

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	41.524	6.349	62.654
comp 2	51.203	5.014	67.668
comp 3	61.095	4.563	72.230


Interprétation :

- **Critère de Kaiser** : Les axes dont la valeur propre > 1 sont retenus (axes 1 à 4).
- **Taux d'inertie cumulé** : Les 2 premiers axes expliquent ~48% de la variance ; les 4 premiers ~64%.
- **Critère du coude** : La rupture de pente est visible après l'axe 2.

Décision : Nous retenons les **2 premiers axes** pour les représentations graphiques.

Cercle des corrélations des variables


```
fviz_pca_var(res.pca, col.var = "contrib",
             gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),
             repel = TRUE) +
  theme_minimal() +
  labs(title = "Cercle des corrélations", subtitle = "Coloré par
contribution aux axes")
```



Interprétation : L'axe 1 (**Adhésion Algorithmique**) est lié aux variables de satisfaction globale. L'axe 2 (**Exploration vs Exploitation**) oppose les variables liées à la découverte de nouveaux contenus à celles liées à la précision des recommandations.

Carte des individus

```
fviz_pca_ind(res.pca,  
             habillage = 3,  
             addEllipses = TRUE,  
             ellipse.type = "confidence",  
             geom = "point",  
             palette = "jco") +  
  theme_minimal() +  
  labs(title = "Individus groupés par Sexe", subtitle = "Ellipses de  
confiance à 95%")
```



Conclusion ACP : Le genre ne constitue pas un facteur de discrimination massif (chevauchement des ellipses). La diversité de perceptions dans l'échantillon suggère que d'autres variables (fréquence, plateforme) jouent un rôle plus structurant.


Analyse en Correspondances Multiples (ACM)

L'ACM est l'équivalent de l'ACP pour les variables qualitatives. Elle permet d'étudier les liens entre les modalités des variables nominales et comportements binaires (Q31–Q35).

```
res.mca <- MCA(data[, c(2:5, 31:35)], graph = FALSE)
```

Nuage des modalités et des variables

```
fviz_mca_var(res.mca, col.var = "contrib",
              gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),
              repel = TRUE) +
  theme_minimal() +
  labs(title = "ACM – Nuage des modalités", subtitle = "Coloré par contribution aux axes")
```



Interprétation : L'axe 1 de l'ACM sépare les profils *engagés* (utilisateurs fréquents, répondant "Oui" aux comportements algorithmiques) des profils *distants*. L'axe 2 distingue selon le niveau d'étude et la tranche d'âge.


Classification Hiérarchique sur Composantes Principales (HCPC)

L'HCPC combine les méthodes factorielles (réduction du bruit) et la classification ascendante hiérarchique pour produire des groupes stables.


```
res.hcpc <- HCPC(res.pca, nb.clust = -1, graph = FALSE)
```

Dendrogramme et Carte des clusters

```
fviz_dend(res.hcpc, rect = TRUE, palette = "jco", rect_fill = TRUE, cex =  
0.5) +  
  labs(title = "Dendrogramme HCPC")
```



```
fviz_cluster(res.hcpc, repel = TRUE, palette = "jco", geom = "point",  
  main = "HCPC - Carte des clusters") +  
  theme_minimal()
```



Synthèse des Profils Identifiés

```
kable(round(res.hcpc$desc.var$test.chi2, 3),
      caption = "Variables discriminantes par cluster (Khi-2)")
```

Variables
discriminantes
par cluster
(Khi-2)

p.valuedf

Q310.004 7

Q4 0.033 21

Sur la base de l'HCPC, nous identifions **3 segments majeurs** :


ClusterNom	Caractéristiques
1	Sceptiques Scores faibles, usage habituel, peu de confiance algorithmique
2	Enthusiastes Scores élevés, usage très fréquent, grande confiance (Netflix/Spotify)
3	Explorateurs Valorisent la découverte, apprécient les surprises algorithmiques

Partitionnement par K-means

En complément de l'HCPC, la méthode K-means (partitionnement itératif) permet de **valider la stabilité** de nos groupes.


Nombre optimal de clusters (Méthode de la Silhouette)

```
fviz_nbclust(res.pca$ind$coord, kmeans, method = "silhouette") +  
  theme_minimal() +  
  labs(title = "Nombre optimal de clusters - Silhouette")
```



Visualisation K-means (k = 3)

```
set.seed(123)  
res.km <- eclust(res.pca$ind$coord, "kmeans", k = 3, graph = FALSE)  
  
fviz_cluster(res.km, palette = "Set2", geom = "point",  
             ellipse.type = "convex",  
             main = "Partitionnement K-means (k=3)") +  
  theme_minimal()
```



Interprétation : Le K-means produit des groupes **très similaires** à ceux de l'HCPC, démontrant la robustesse de la segmentation. Les frontières nettes entre clusters confirment que les individus d'un même groupe partagent des perceptions cohérentes face aux algorithmes.

Conclusion Générale et Recommandations

Synthèse des résultats

L'analyse multidimensionnelle révèle une structure bidimensionnelle claire dans les données. L'adhésion aux algorithmes de recommandation dépend principalement de deux facteurs : la **fréquence d'usage** et la **perception de la personnalisation**.

Les méthodes HCPC et K-means convergent vers **3 profils stables** : les Sceptiques, les Enthousiastes et les Explorateurs Curieux.

Recommandations Stratégiques

1. **Améliorer la Transparence** (Cluster 1 – Sceptiques) : Expliquer *pourquoi* une recommandation est faite renforcerait la confiance des utilisateurs critiques.
2. **Favoriser la Sérendipité** (Cluster 3 – Explorateurs) : Intégrer du contenu « hors profil » pour satisfaire le besoin de nouveauté.
3. **Personnalisation Dynamique** : Ajuster l'équilibre *confort/nouveauté* selon le profil identifié par clustering.

Limites et Perspectives

Cette étude porte sur **45 individus**, principalement jeunes et étudiants. Une extension à une population plus diverse permettrait de généraliser ces résultats. L'intégration de métriques comportementales réelles (temps de session, taux de clic) permettrait de confronter perceptions et comportements effectifs.